Clasificación Multitarea de Emociones en Letras Musicales en Español mediante Fine-Tuning de mRoBERTa

Por
Jheeremy Manuel Alvarez Astete

Tesis presentada a la
Escuela Profesional de Ciencia de la Computación
de la
UNIVERSIDAD NACIONAL DE SAN AGUSTÍN
como requisito
para obtener el título profesional
de
Licenciado en Ciencia de la Computación

Arequipa, Perú
2026

Universidad Nacional de San Agustín
Facultad de Ingeniería de Producción y Servicios
Escuela Profesional de Ciencia de la Computación

Clasificación Multitarea de Emociones en Letras Musicales en Español mediante Fine-Tuning de mRoBERTa

Tesis de graduación presentada por el bachiller Jheeremy Manuel Alvarez Astete en cumplimiento de los requisitos para obtener el título profesional de Licenciado en Ciencia de la Computación.

Arequipa, [completar fecha de sustentación] del 2026

Aprobado por:

[Nombre del presidente del jurado]
Presidente

[Nombre del secretario del jurado]
Secretario

[Nombre del integrante del jurado]
Integrante

[Nombre del jurado externo, si aplica]

Externo

[Espacio reservado para la dedicatoria]

Índice general

Agradecimientos VI

Resumen VII

1. Introducción **1**

1.1. Contexto y Motivación 1
1.2. Definición del problema 3
1.3. Justificación 4
1.4. Objetivos 4
1.5. Organización de la tesis 5

2. Estado del Arte **7**

2.1. Consideraciones iniciales 7
2.2. Evolución de los métodos de análisis emocional en lírica 7
2.3. Arquitecturas Transformer aplicadas al dominio lírico 8
2.4. Modelos de lenguaje para el español 8
2.5. Estrategias de representación de secuencias 9
2.6. Anotación y validación de etiquetas emocionales 9
2.7. El corpus lírico empleado 10
2.8. Aprendizaje multitarea sobre conjuntos heterogéneos 11
2.9. Consideraciones finales 11

3. Marco Teórico **13**

3.1. Consideraciones iniciales 13
3.2. La canción popular como objeto de análisis 13
3.2.1. Estructura formal de la canción 13
3.2.2. El lenguaje lírico y la significación indirecta 14
3.2.3. La letra y la emoción musical 14
3.3. Modelos de lenguaje basados en Transformer 15

3.3.1. La arquitectura Transformer . . . 15
3.3.2. Modelos codificadores: BERT y RoBERTa . . . 15
3.3.3. mRoBERTa: el modelo empleado en esta propuesta . . . 15
3.4. Estrategias de adaptación . . . 16
3.4.1. Ajuste fino . . . 16
3.4.2. Aprendizaje multitarea . . . 16
3.4.3. Estrategias de agrupamiento . . . 17
3.5. Representación computacional de la emoción . . . 17
3.5.1. Modelos dimensionales . . . 17
3.5.2. Modelos categóricos y emociones consideradas . . . 18
3.5.3. Léxicos afectivos . . . 20
3.6. Arquitectura propuesta . . . 20
3.7. Evaluación . . . 20
3.7.1. Métricas empleadas . . . 20
3.7.2. Justificación de las métricas . . . 22
3.7.3. El acuerdo entre anotadores como referencia . . . 23
3.8. Consideraciones finales . . . 23

4. Propuesta **24**
4.1. Consideraciones iniciales . . . 24
4.2. Visión general de la propuesta . . . 24
4.3. Construcción de los conjuntos de datos . . . 25
4.3.1. Corpus lírico: MERGE Lyrics Complete . . . 25
4.3.2. Traducción automática al español . . . 25
4.3.3. Control de calidad de la traducción . . . 26
4.3.4. Corpus auxiliar: subconjunto en español de BRIGHTER . . . 26
4.3.5. Preprocesamiento y tokenización . . . 27
4.4. Configuración del modelo . . . 28
4.4.1. Codificador . . . 28
4.4.2. Estrategias de agrupamiento . . . 28
4.4.3. Cabezales de predicción y funciones de pérdida . . . 29
4.5. Procedimiento de entrenamiento . . . 30
4.5.1. Muestreo alternante . . . 30
4.5.2. Hiperparámetros . . . 31
4.5.3. Selección del modelo y reproducibilidad . . . 31
4.6. Diseño experimental . . . 32

4.6.1. Configuraciones evaluadas 32
4.6.2. Comparación con la línea base publicada 33
4.6.3. Análisis estadístico 33
4.7. Análisis cualitativo 34
4.8. Entorno de implementación 34
4.9. Amenazas a la validez 35
4.10. Consideraciones finales 35

Índice de figuras

3.1. Modelo circunflejo del afecto y sus cuatro cuadrantes, adaptado de Russell [37]. 18
3.2. Distribución de las categorías emocionales anotadas en los conjuntos que integran BRIGHTER. Cada barra indica el número de instancias etiquetadas por emoción y su porcentaje. Tomado de Muhammad et al. [26]. 19
3.3. Arquitectura multitarea propuesta. Cada lote procede de un único corpus y activa únicamente el cabezal correspondiente; el codificador compartido recibe actualizaciones de ambas tareas, lo que constituye el mecanismo de transferencia. 21

4.1. Fases de la propuesta. Las dos primeras construyen los conjuntos de datos; la tercera entrena las configuraciones experimentales; las dos últimas analizan los resultados. 25

Índice de cuadros

2.1. Comparación de trabajos previos y posicionamiento de la propuesta 12

3.1. Métricas de evaluación empleadas en cada tarea 22

4.1. Conjuntos de datos empleados en la propuesta 27
4.2. Hiperparámetros de entrenamiento 31
4.3. Configuraciones experimentales 32

Agradecimientos

[Espacio reservado para los agradecimientos]

Resumen

El análisis automático de emociones en letras musicales representa un desafío complejo dentro del Procesamiento del Lenguaje Natural (PLN), debido al uso frecuente de metáforas, ambigüedad semántica y estructuras poéticas [24]. El sentido afectivo de una palabra en la lírica depende del contexto en que aparece, propiedad que los modelos basados en Transformer pueden capturar, pero cuyo aprovechamiento requiere supervisión emocional abundante durante el ajuste fino, escasa para el español en este dominio.

Esta tesis aborda dicha limitación mediante el fine-tuning del modelo mRoBERTa (MarIA) sobre un corpus lírico en español, adaptado por traducción automática a partir de MERGE Lyrics Complete, e incorporando de manera simultánea una tarea auxiliar de reconocimiento emocional sobre texto en español general anotado por hablantes nativos. La hipótesis planteada sostiene que el conocimiento emocional adquirido sobre lenguaje cotidiano se transfiere al dominio lírico a través del codificador compartido, compensando parcialmente la escasez de datos líricos anotados. La evaluación considera además distintas estrategias de representación vectorial de la secuencia aplicables a textos extensos [49].

Dado que la emoción percibida en una canción constituye un juicio subjetivo, los resultados se interpretan en relación con el nivel de acuerdo entre anotadores humanos documentado para los recursos empleados, y no respecto de una exactitud absoluta. La investigación contribuye al avance del PLN en español para dominios artísticos y habilita aplicaciones potenciales en musicoterapia y en sistemas de recomendación musical sensibles al estado emocional del usuario.

Palabras clave: procesamiento del lenguaje natural, análisis de emociones, lírica musical, español, modelos Transformer, aprendizaje multitarea.

Capítulo 1

Introducción

El análisis automático de sentimientos y emociones (ASE) en letras musicales representa un desafío complejo dentro del Procesamiento del Lenguaje Natural (PLN), ya que el lenguaje lírico en español utiliza frecuentemente metáforas, ambigüedad semántica y estructuras poéticas. Esta tesis aborda dicho desafío mediante el fine-tuning del modelo de lenguaje mRoBERTa (MarIA) [12] sobre el dominio de la lírica musical en español. La contribución central de la investigación consiste en incorporar conocimiento emocional del español general, proveniente de texto anotado por hablantes nativos, como señal complementaria durante el ajuste fino del modelo, con el propósito de mejorar su capacidad de interpretar el contenido emocional de textos líricos. El aprendizaje multitarea (MTL) es el mecanismo empleado para esta transferencia, y no un fin en sí mismo.

1.1. Contexto y Motivación

El ASE en texto es una tarea fundamental en el PLN. Su aplicación en el dominio de la lírica musical presenta un desafío significativo debido al uso de lenguaje poético, metáforas y ambigüedad semántica, lo que dificulta la interpretación computacional precisa de las emociones. La literatura ha destacado que el lenguaje lírico transmite emociones de forma implícita y subjetiva [24].

La aparición de arquitecturas basadas en Transformer, como BERT [10], ha permitido alcanzar el estado del arte en clasificación de texto gracias al aprendizaje por transferencia (fine-tuning). La literatura ha demostrado que el ajuste fino de estas arquitecturas es una estrategia efectiva y ampliamente adoptada para tareas de clasificación de texto [43]. Para el idioma español, la familia de modelos MarIA ha establecido un nuevo estándar: mRoBERTa fue entrenado con un corpus masivo y limpio de 570 GB extraído del Archivo Web del Español de la Biblioteca Nacional de España [12]. Estudios recientes en análisis de sentimientos en

español confirman que el fine-tuning con modelos de la familia MarIA logra un rendimiento superior frente a otras alternativas evaluadas [5].

La dificultad específica del dominio lírico radica en que el significado emocional de una palabra depende del contexto en que aparece: un mismo término puede expresar afectos opuestos según el verso que lo rodea. Esta propiedad, conocida como ambigüedad contextual, es precisamente aquello que los modelos basados en Transformer están en condiciones de capturar, ya que generan representaciones vectoriales sensibles al contexto en lugar de asignar un valor fijo a cada palabra [10]. No obstante, la capacidad del modelo para explotar esa sensibilidad depende de la cantidad y la calidad de la supervisión emocional que reciba durante el ajuste fino, y los corpus líricos anotados disponibles para el español son escasos.

Frente a esta limitación, la presente tesis recurre al aprendizaje multitarea como mecanismo de transferencia: junto a la tarea principal de predicción emocional sobre lírica, el modelo se entrena simultáneamente con una tarea auxiliar de reconocimiento de emociones sobre texto en español general anotado por hablantes nativos [27]. La hipótesis subyacente es que el conocimiento emocional adquirido sobre lenguaje cotidiano puede transferirse al dominio lírico a través del codificador compartido, compensando parcialmente la escasez de datos líricos anotados en español. Esta estrategia se apoya en el principio de que el aprendizaje multitarea resulta beneficioso cuando las tareas involucradas aportan señales complementarias y no redundantes entre sí [6, 36].

Motivación

Más allá del interés metodológico en el PLN, esta investigación se motiva por dos aplicaciones concretas. La primera es la musicoterapia: la literatura ha documentado el uso de música como herramienta terapéutica no farmacológica, y ha señalado el potencial de los métodos de inteligencia artificial para personalizar los estímulos musicales que un terapeuta ofrece a cada paciente, tarea que resulta difícil de escalar manualmente [38]. La segunda es la recomendación musical sensible a la emoción: se ha mostrado que los sistemas de recomendación convencionales, al ignorar el contexto emocional del usuario y depender únicamente del historial de escucha, generan sugerencias que no siempre se ajustan al estado de ánimo actual de la persona [2]. Un modelo capaz de caracterizar con precisión el contenido emocional de una letra en español podría, en trabajos futuros, servir como insumo para ambas aplicaciones.

1.2. Definición del problema

El problema que aborda esta tesis es la dificultad de los modelos de lenguaje para interpretar el contenido emocional de la lírica musical en español, dominio en el que el sentido afectivo se expresa de forma indirecta y depende del contexto [24]. Esta dificultad se manifiesta en dos niveles complementarios.

Nivel lingüístico. El lenguaje lírico expresa emociones mediante metáforas, ironía y construcciones poéticas, de modo que el valor afectivo de una palabra no es estable sino que varía según el verso en que aparece. Los enfoques que asignan a cada término un valor emocional fijo, como los basados en léxicos afectivos, resultan insuficientes ante esta variabilidad, puesto que operan sobre palabras aisladas y no sobre su contexto.

Nivel de datos. La interpretación contextual requiere supervisión emocional abundante durante el ajuste fino, pero los corpus líricos anotados en español son escasos: la mayoría de recursos disponibles públicamente se encuentran en inglés [22], lo que obliga a recurrir a traducción automática y limita la fidelidad lingüística del material de entrenamiento.

Sobre la naturaleza subjetiva de la tarea. La emoción percibida en una canción no constituye un valor objetivo y único, sino un juicio sobre el cual distintas personas pueden discrepar legítimamente. Por esta razón, el desempeño de un modelo en esta tarea no se evalúa contra una verdad absoluta, sino contra el grado de coincidencia alcanzado entre anotadores humanos, el cual establece un techo de referencia para el rendimiento alcanzable. Los recursos empleados en esta tesis reportan explícitamente dicho nivel de acuerdo [27, 8], lo que permite interpretar los resultados obtenidos en relación con ese límite y no respecto de una exactitud perfecta inalcanzable por construcción.

Fuera de alcance. Siguiendo el criterio de mantener un alcance viable dentro del tiempo disponible, quedan fuera de esta tesis y se plantean como trabajo futuro: la comparación sistemática entre distintos codificadores preentrenados en español (por ejemplo, arquitecturas basadas en DeBERTa [44] frente a mRoBERTa), el manejo jerárquico de secuencias que excedan el límite de tokens del modelo mediante segmentación por estrofas [30], la incorporación de información acústica, y la comparación contra modelos de lenguaje de gran escala en modo de aprendizaje por instrucciones sin ajuste fino.

Esto conduce a la siguiente pregunta de investigación: ¿en qué medida el entrenamiento conjunto con una tarea auxiliar de reconocimiento emocional sobre texto en español general, anotado por hablantes nativos, mejora la capacidad de un modelo basado en mRoBERTa para interpretar el contenido emocional de letras musicales en español, en comparación con un modelo entrenado únicamente sobre el corpus lírico?

1.3. Justificación

Esta investigación se justifica por las siguientes razones:

1. *Brecha de recursos líricos en español*: la investigación en reconocimiento emocional de lírica se ha desarrollado predominantemente sobre corpus en inglés [24, 22], mientras que el español, pese a su extensión como lengua de producción musical, carece de recursos anotados equivalentes. Esta tesis contribuye a reducir dicha brecha proponiendo una estrategia que aprovecha datos emocionales en español nativo disponibles en otros dominios textuales [27].

2. *Pertinencia de la transferencia entre dominios*: dado que ampliar manualmente los corpus líricos anotados resulta costoso, evaluar si el conocimiento emocional del español general transfiere al dominio lírico constituye una vía metodológicamente relevante y de aplicación directa en escenarios con datos especializados escasos [18, 36].

3. *Necesidad de etiquetas verificables*: los trabajos del área han empleado estrategias de anotación con niveles de rigor diversos, desde léxicos afectivos aplicados automáticamente [50] hasta comités de anotadores humanos que reportan métricas de acuerdo entre evaluadores [8, 22]. Esta tesis adopta explícitamente una estrategia reconocida para cada etiqueta empleada y documenta su nivel de consistencia, en lugar de asumir sin verificación la validez de las anotaciones.

4. *Contribución al PLN en español y aplicaciones derivadas*: el proyecto proporciona evidencia empírica y un procedimiento reproducible para adaptar modelos de lenguaje preentrenados a dominios artísticos en español, con potencial de aplicación en musicoterapia [38] y en sistemas de recomendación musical sensibles a la emoción [2].

1.4. Objetivos

Objetivo general

Evaluar en qué medida el entrenamiento multitarea con texto emocional en español anotado por hablantes nativos mejora la clasificación emocional de letras musicales en español mediante fine-tuning de mRoBERTa.

Objetivos específicos

1. Construir un corpus lírico en español a partir de MERGE Lyrics Complete [22], conjunto de 2568 letras en inglés anotadas con cuadrantes de Russell validados manualmente y con valores continuos de valencia y activación, adaptándolo mediante traducción automática y documentando las limitaciones que este procedimiento introduce en la calidad de las etiquetas.

2. Incorporar un subconjunto en español nativo de un banco de datos de emociones anotado por hablantes nativos [27] como fuente de la tarea auxiliar, verificando el nivel de acuerdo entre anotadores reportado para dicho recurso.

3. Implementar el esquema de entrenamiento conjunto sobre ambos conjuntos de datos, mediante un procedimiento de muestreo que permita entrenar las dos tareas sin mezclar etiquetas de distinta naturaleza.

4. Evaluar estrategias de representación vectorial de la secuencia (token de inicio, promedio de embeddings y un mecanismo de atención aprendida) y su impacto en la interpretación del contenido emocional de textos líricos extensos [49].

5. Evaluar el modelo mediante métricas estándar de regresión (correlación de Pearson, error cuadrático medio) y de clasificación (exactitud, F1-score), contrastando los resultados tanto con un modelo entrenado únicamente sobre el corpus lírico como con la línea base publicada para el corpus original [22].

6. Analizar cualitativamente el comportamiento del modelo ante fragmentos líricos que presenten lenguaje figurado o ambigüedad contextual, con el fin de caracterizar sus aciertos y limitaciones en los casos propios del dominio [40].

1.5. Organización de la tesis

El presente documento se organiza de la siguiente manera. El Capítulo 2 revisa los trabajos relacionados, abarcando la evolución del reconocimiento emocional en lírica desde los enfoques basados en recursos léxicos hasta las arquitecturas actuales, así como los avances del PLN para el idioma español. El Capítulo 3 presenta el marco teórico, donde se describen la arquitectura Transformer, el modelo mRoBERTa, los fundamentos del aprendizaje multitarea y los modelos psicométricos empleados para representar la emoción. El Capítulo 4 detalla la propuesta metodológica, incluyendo la construcción del corpus, el procedimiento de entrenamiento conjunto y el plan de evaluación. El Capítulo 5 expone los experimentos

realizados y sus resultados, tanto cuantitativos como cualitativos. Finalmente, el Capítulo 6 recoge las conclusiones, las limitaciones identificadas y las líneas de trabajo futuro.

Capítulo 2

Estado del Arte

2.1. Consideraciones iniciales

El reconocimiento automático de emociones en letras musicales constituye un subcampo del PLN cuya dificultad proviene de la naturaleza metafórica y ambigua del lenguaje lírico [24]. Este capítulo revisa las contribuciones que han abordado esta tarea, organizadas en cuatro ejes: la evolución de los métodos empleados, el desarrollo de modelos de lenguaje para el español, las estrategias de representación de secuencias, y los procedimientos de anotación y validación de las etiquetas emocionales. El último eje recibe atención particular, dado que la calidad de las anotaciones condiciona la interpretación de cualquier resultado en esta tarea.

2.2. Evolución de los métodos de análisis emocional en lírica

Los trabajos iniciales en esta área se apoyaron en recursos léxicos combinados con clasificadores de aprendizaje automático tradicional. Kim y Kwon [16] emplearon selección de características mediante análisis sintáctico parcial para clasificar emociones en letras, mientras que Raschka [33] utilizó aprendizaje automático sobre características léxicas para predecir el estado de ánimo de canciones. Estos enfoques establecieron la viabilidad de la tarea empleando únicamente el texto, pero compartían una limitación: al asignar valores afectivos fijos a cada término, resultaban insensibles al contexto en que las palabras aparecen.

La incorporación de arquitecturas neuronales permitió capturar dependencias contextuales con mayor eficacia. Delbouys et al. [9] exploraron la combinación de información acústica y textual mediante redes neuronales profundas, línea que también siguieron trabajos posteriores orientados a la multimodalidad. La presente tesis se distancia de estos enfoques al

concentrarse exclusivamente en el texto, decisión que responde al interés por evaluar hasta qué punto el contenido lírico por sí solo permite inferir la emoción de una canción.

2.3. Arquitecturas Transformer aplicadas al dominio lírico

La aparición de los modelos basados en Transformer modificó sustancialmente el panorama de la clasificación textual. Agrawal et al. [1] demostraron que el ajuste fino de estas arquitecturas supera consistentemente a los métodos tradicionales en el reconocimiento emocional de lírica, validando el enfoque de aprendizaje por transferencia para este dominio. En una línea complementaria, Revathy y Krishnakumar [35] desarrollaron un modelo especializado para predecir emociones discretas en letras, mostrando la capacidad de estas arquitecturas para distinguir categorías emocionales específicas.

Estos trabajos comparten dos características que delimitan el espacio en que se inscribe esta tesis. La primera es que fueron desarrollados y evaluados sobre corpus en inglés, de modo que sus conclusiones no se transfieren automáticamente al español. La segunda es que abordan la tarea de forma monotarea, entrenando el modelo exclusivamente sobre datos del dominio lírico, sin explorar si conocimiento emocional procedente de otros dominios textuales podría compensar la escasez de datos especializados.

2.4. Modelos de lenguaje para el español

La aplicación directa de modelos multilingües al español ha resultado inferior a la de modelos entrenados específicamente en este idioma [7, 12]. Cañete et al. [7] presentaron BETO, el primer modelo de la familia BERT preentrenado exclusivamente con textos en español, a partir de fuentes internacionales diversas. Posteriormente, Gutiérrez-Fandiño et al. [12] desarrollaron la familia MarIA, cuya variante mRoBERTa fue entrenada con un corpus extraído del Archivo Web del Español de la Biblioteca Nacional de España, estableciendo un nuevo referente para tareas de comprensión del lenguaje en este idioma. Estudios aplicados confirman que el ajuste fino de modelos de esta familia alcanza un rendimiento superior en análisis de sentimientos en español [5].

Más recientemente, Vaca Serrano et al. [44] propusieron RigoBERTa, basada en la arquitectura DeBERTa, que reportó mejores resultados que mRoBERTa en la mayoría de las tareas de comprensión del lenguaje evaluadas. La comparación sistemática entre ambos codificadores se plantea como trabajo futuro en esta tesis, según lo expuesto en el capítulo

anterior.

Conviene señalar una característica del corpus de preentrenamiento de mRoBERTa que resulta pertinente para el dominio lírico: al provenir mayoritariamente de fuentes web del dominio español peninsular, su exposición a variedades del español latinoamericano es menor que la de modelos entrenados sobre fuentes internacionales como BETO [7]. Dado que Latinoamérica constituye el mercado musical de mayor crecimiento sostenido a escala global [13], una proporción considerable de la producción lírica en español procede de variedades poco representadas en dicho corpus, lo que constituye una limitación que deberá considerarse al interpretar los resultados.

2.5. Estrategias de representación de secuencias

La obtención del vector que representa un texto completo constituye una decisión arquitectónica con impacto directo en el rendimiento. La convención en modelos de la familia BERT consiste en emplear el vector asociado al token inicial de la secuencia [10]. Sin embargo, diversos trabajos han cuestionado la idoneidad de esta estrategia para secuencias extensas. Yamato et al. [49] propusieron un método de agrupamiento ponderado entrenable y mostraron que las estrategias basadas en el promedio de los embeddings resultan más efectivas que el token de clasificación en tareas de clasificación textual. Xing et al. [48] extendieron esta comparación al análisis de sentimientos, y hallazgos similares se han reportado en tareas de clasificación de textos periodísticos [41].

Estos resultados provienen de dominios textuales de estructura convencional. Su validez en el caso de la lírica, donde la organización del texto en versos y estrofas y la presencia de repeticiones alteran la distribución de la información a lo largo de la secuencia, no ha sido establecida empíricamente.

2.6. Anotación y validación de etiquetas emocionales

Dado que la emoción percibida en una canción constituye un juicio subjetivo, la construcción de la verdad de referencia representa un problema metodológico central en esta área. La literatura ha empleado cuatro estrategias principales.

La primera consiste en la anotación automática mediante léxicos afectivos, en la que los valores emocionales de las palabras de una letra se promedian para obtener una etiqueta a nivel de canción. Çano y Morisio [50] aplicaron este procedimiento para construir un corpus lírico anotado. Su ventaja reside en la escalabilidad; su limitación, en que opera sobre palabras aisladas sin considerar el contexto.

La segunda emplea etiquetas generadas por usuarios en plataformas musicales como fuente aproximada de la emoción percibida. Louro et al. [22] describen el procesamiento de este tipo de anotaciones, incluyendo el descarte de valores atípicos y la verificación posterior, así como los sesgos que introducen.

La tercera recurre a comités de anotadores humanos que califican cada texto de forma independiente, promediando sus juicios. Dahary et al. [8] aplicaron este procedimiento sobre letras de música popular empleando el esquema de emociones básicas de Ekman [11]. El grado de coincidencia entre anotadores se cuantifica mediante métricas de acuerdo, cuyo valor establece un límite superior de referencia para el rendimiento alcanzable por un sistema automático.

La cuarta, de aparición reciente, emplea modelos de lenguaje de gran escala como anotadores, calibrando sus juicios contra un subconjunto anotado por personas [20].

El recurso empleado en esta tesis como fuente de la tarea auxiliar [27] corresponde a la tercera estrategia y reporta explícitamente su nivel de acuerdo entre anotadores, lo que permite situar los resultados obtenidos respecto de ese límite.

2.7. El corpus lírico empleado

El corpus que aporta las anotaciones emocionales del dominio lírico en esta tesis es MERGE Lyrics Complete [22], publicado en 2026 por el grupo de recuperación de información musical de la Universidad de Coimbra. Se compone de 2568 letras en inglés, distribuidas entre los cuatro cuadrantes de Russell con un desequilibrio moderado, y constituye, según sus autores, el mayor conjunto de datos bimodal con control de calidad disponible públicamente para el reconocimiento emocional musical estático.

Su construcción siguió un procedimiento semiautomático. Las etiquetas emocionales asignadas por editores profesionales de la plataforma AllMusic se proyectaron sobre el plano de valencia y activación empleando el léxico de Warriner [46], y a partir de esa proyección se determinó el cuadrante correspondiente a cada canción. Las piezas situadas cerca del origen del plano, cuya emoción resultaba ambigua, fueron descartadas. Posteriormente, ocho evaluadores realizaron una inspección ciega en la que anotaron las letras según los cuadrantes de Russell, conservándose únicamente aquellas cuya anotación coincidió con el cuadrante derivado automáticamente. Este procedimiento sitúa al corpus en la tercera de las estrategias descritas en la sección anterior por lo que respecta a los cuadrantes.

Los valores continuos de valencia y activación, en cambio, no fueron sometidos a validación manual: proceden directamente de la proyección automática de las etiquetas emocionales sobre el léxico [22]. Esta diferencia resulta pertinente para la presente tesis, puesto que la

tarea de regresión se apoya en dichos valores, y se asume como limitación declarada.

El corpus proporciona además una línea base de referencia. Empleando representaciones obtenidas de un modelo de la familia RoBERTa sobre letras únicamente, sus autores reportan una puntuación F1 de 71.40 por ciento en la clasificación de cuadrantes, con coeficientes de determinación de 0.366 para la activación y 0.569 para la valencia [22]. Cabe señalar que su implementación trunca las letras que exceden la longitud máxima admitida por el modelo, circunstancia que los propios autores identifican como una restricción del procedimiento.

Finalmente, los autores plantean como línea de trabajo futuro la extensión del corpus a otros idiomas mediante traducción automática [22]. La presente tesis desarrolla precisamente esa extensión para el español, lo que refuerza la pertinencia del enfoque adoptado.

2.8. Aprendizaje multitarea sobre conjuntos heterogéneos

El aprendizaje multitarea fue formalizado por Caruana [6] como una forma de transferencia inductiva en la que varias tareas se aprenden en paralelo compartiendo una representación común, de modo que lo aprendido para una tarea beneficia a las demás. En el ámbito del PLN, Liu et al. [18] aplicaron este principio sobre arquitecturas Transformer, empleando capas inferiores compartidas y capas superiores específicas por tarea, y demostraron que las representaciones resultantes permiten adaptación a nuevos dominios con una cantidad sustancialmente menor de datos etiquetados específicos.

Este último hallazgo resulta directamente pertinente para el problema abordado en esta tesis, en el que la escasez de datos líricos anotados en español constituye la limitación principal. El procedimiento de entrenamiento sobre conjuntos de datos heterogéneos, que no comparten ni textos ni etiquetas, sigue el esquema propuesto en dicho trabajo.

2.9. Consideraciones finales

De la revisión efectuada se desprenden tres conclusiones. Primera: las arquitecturas Transformer constituyen el estado del arte en la clasificación emocional de lírica, si bien la evidencia disponible procede mayoritariamente del inglés. Segunda: para el español existen modelos monolingües de calidad contrastada, aunque ninguno ha sido adaptado específicamente al dominio lírico. Tercera: la aplicación del aprendizaje multitarea como mecanismo de transferencia desde dominios textuales con mayor disponibilidad de anotaciones hacia el dominio lírico en español no ha sido evaluada, lo que constituye el espacio que esta tesis ocupa.

Cuadro 2.1: Comparación de trabajos previos y posicionamiento de la propuesta

Autores	Año	Título del trabajo	Aporte principal	Diferencia con esta propuesta
Kim y Kwon [16]	2011	Lyrics-Based Emotion Classification Using Feature Selection by Partial Syntactic Analysis	Clasificación emocional de lírica mediante selección de características léxicas	Asigna valores fijos por palabra; esta propuesta emplea representaciones contextuales sensibles al verso
Agrawal et al. [1]	2021	Transformer-Based Approach Towards Music Emotion Recognition from Lyrics	El ajuste fino de arquitecturas Transformer supera a los métodos previos en lírica	Monotarea y en inglés; esta propuesta añade una tarea auxiliar en español y opera sobre lírica traducida
Gutiérrez-Fandiño et al. [12]	2022	MarIA: Spanish Language Models	Modelo monolingüe de referencia para comprensión del lenguaje en español	Modelo de propósito general; esta propuesta lo adapta por fine-tuning al dominio lírico
Yamato et al. [49]	2023	Trainable Weighted Pooling Method for Text Classification with BERT	El promedio y la ponderación aprendida superan al token de clasificación en secuencias extensas	Dominio textual convencional; esta propuesta evalúa las tres estrategias sobre lírica en español
Liu et al. [18]	2019	Multi-Task Deep Neural Networks for Natural Language Understanding	El entrenamiento conjunto sobre tareas heterogéneas mejora la adaptación con pocos datos	Tareas de comprensión general; esta propuesta aplica el esquema a la transferencia hacia el dominio lírico
Muhammad et al. [26]	2025	BRIGHTER: BRIdging the Gap in Human-Annotated Textual Emotion Recognition Datasets for 28 Languages	Corpus emocional multilingüe anotado por hablantes nativos, con fiabilidad reportada	Dominio de redes sociales; esta propuesta lo emplea como fuente de la tarea auxiliar, no como objetivo final
Louro et al. [22]	2026	MERGE: A Bimodal Audio-Lyrics Dataset for Static Music Emotion Recognition	Corpus lírico con cuadrantes validados manualmente y línea base reproducible	Disponible solo en inglés; esta propuesta desarrolla la extensión al español que sus autores plantean

Capítulo 3

Marco Teórico

3.1. Consideraciones iniciales

Este capítulo expone los fundamentos que sustentan la propuesta. Dado que el objeto de análisis es la letra de canciones, la exposición comienza por caracterizar ese objeto desde la musicología y la lingüística: cómo se organiza formalmente una canción popular, qué recursos emplea el lenguaje lírico para expresar significado y qué papel desempeña la letra en la emoción que una canción transmite. Solo después se presentan los fundamentos computacionales, los modelos de representación emocional, la arquitectura propuesta y los criterios de evaluación.

3.2. La canción popular como objeto de análisis

3.2.1. Estructura formal de la canción

La canción popular se organiza en secciones con funciones diferenciadas. La forma estrófica, la más simple y duradera, repite una misma música para todas las estrofas del texto. Sobre ella se construyó la forma verso-estribillo, predominante en la música popular contemporánea, en la que alternan dos tipos de sección con funciones opuestas.

El verso presenta texto variable y hace avanzar la narración, mientras que el estribillo mantiene el texto invariable y concentra el material lírico principal de la pieza, incluido el título o el gancho [42]. Entre ambos puede aparecer el preestribillo, sección que surgió a mediados de la década de 1960 como expansión de la parte final del verso y cuya función es acumular tensión y retrasar la llegada del estribillo [42]. Nobile [29] describe la secuencia verso, preestribillo y estribillo como un proceso formal dirigido, en el que el estribillo constituye el punto de llegada.

De esta organización se derivan dos consecuencias para el análisis automático. La primera es que la letra de una canción no es un texto homogéneo: contiene segmentos de función narrativa y segmentos de función sintética, cuyo peso emocional puede diferir. La segunda es que la repetición literal del estribillo introduce una redundancia léxica considerable, que altera la distribución de frecuencias respecto de la prosa convencional.

3.2.2. El lenguaje lírico y la significación indirecta

El texto de una canción funciona como texto literario y emplea los recursos propios de la poesía. Entre ellos, la metáfora ocupa un lugar central. Lakoff y Johnson [17] sostienen que la metáfora no constituye un adorno del lenguaje sino un mecanismo cognitivo mediante el cual se comprende un dominio conceptual en términos de otro, de modo que el significado metafórico es constitutivo del pensamiento ordinario y no una desviación de él.

Esta propiedad tiene consecuencias directas sobre el análisis emocional automático. En la lírica, el estado afectivo se expresa con frecuencia de forma indirecta, mediante imágenes cuyo valor emocional no se deduce del significado literal de las palabras que las componen. Un mismo término puede expresar afectos opuestos según el verso en que aparezca, fenómeno que impide asignar a cada palabra un valor afectivo estable. La literatura ha señalado que el lenguaje lírico transmite emociones de forma implícita y subjetiva [24].

3.2.3. La letra y la emoción musical

El estudio de la emoción en música distingue entre la emoción que una pieza expresa, la que el oyente percibe y la que efectivamente se induce en él [14]. La presente tesis se sitúa en el segundo plano: el objetivo es predecir la emoción que un conjunto de personas coincidiría en percibir a partir del texto, no la que el autor experimentó ni la que el oyente llega a sentir.

Respecto del peso específico de la letra frente a la música, Barradas y Sakka [3] examinaron su contribución desde una perspectiva intercultural y hallaron que su importancia varía según el oyente y el contexto, sin que exista un patrón único. Esta variabilidad refuerza el carácter subjetivo de la tarea y justifica que la evaluación se interprete respecto del acuerdo alcanzado entre anotadores, tal como se expone más adelante.

3.3. Modelos de lenguaje basados en Transformer

3.3.1. La arquitectura Transformer

La arquitectura Transformer [45] constituye la base de los modelos de lenguaje contemporáneos. A diferencia de las arquitecturas recurrentes, que procesan el texto secuencialmente, emplea el mecanismo de autoatención para ponderar la relevancia de cada elemento de la secuencia respecto de todos los demás. De ello se derivan dos propiedades relevantes para el análisis de textos líricos: la capacidad de relacionar elementos distantes sin degradación de la señal, y la posibilidad de procesar la secuencia en paralelo.

La consecuencia central para esta tesis es que la representación vectorial asignada a un token depende de los tokens que lo acompañan. Un mismo término recibe representaciones distintas según el contexto, propiedad que responde directamente al problema de la significación indirecta descrito en la sección anterior.

3.3.2. Modelos codificadores: BERT y RoBERTa

Los modelos de la familia BERT [10] emplean la componente codificadora de la arquitectura Transformer para generar representaciones contextuales del texto. Su preentrenamiento combina dos objetivos: la predicción de tokens enmascarados y la predicción de continuidad entre pares de oraciones.

RoBERTa [19] mantiene la misma arquitectura pero modifica el procedimiento de preentrenamiento: elimina el objetivo de predicción de continuidad, aplica enmascaramiento dinámico, emplea lotes de mayor tamaño y entrena sobre un volumen sustancialmente mayor de texto. Estas modificaciones mejoran el rendimiento sin alterar la estructura del modelo, lo que convierte a RoBERTa en la base habitual de los modelos monolingües desarrollados posteriormente.

3.3.3. mRoBERTa: el modelo empleado en esta propuesta

El modelo base de esta tesis es mRoBERTa, perteneciente a la familia MarIA [12], que aplica la arquitectura RoBERTa al español monolingüe.

Respecto de su preentrenamiento, el corpus procede del Archivo Web del Español de la Biblioteca Nacional de España, del que se obtuvieron aproximadamente 570 gigabytes de texto limpio tras un proceso de filtrado y deduplicación [12]. Este volumen supera ampliamente al de los modelos monolingües previos para el español, entre ellos BETO [7].

Respecto de sus características técnicas, la variante base emplea doce capas codificadoras, una dimensión oculta de 768 unidades y doce cabezales de atención, con una longitud má-

xima de secuencia de 512 tokens. La tokenización se realiza mediante codificación por pares de bytes, lo que permite representar palabras no vistas durante el preentrenamiento descomponiéndolas en unidades subléxicas, propiedad relevante en un dominio donde abundan neologismos y formas coloquiales.

Su elección para esta tesis responde a que los modelos monolingües superan a los multilingües en tareas de comprensión del lenguaje en español [12], y a que el ajuste fino de modelos de esta familia ha mostrado un rendimiento superior en análisis de sentimientos en este idioma [5].

Debe señalarse una limitación derivada de su corpus de preentrenamiento. Al proceder de fuentes web del dominio español peninsular, su exposición a variedades latinoamericanas es menor que la de modelos entrenados sobre fuentes internacionales [7]. Esta circunstancia resulta pertinente porque el corpus de la tarea auxiliar corresponde a español latinoamericano [26], y se retoma al interpretar los resultados.

3.4. Estrategias de adaptación

3.4.1. Ajuste fino

El ajuste fino adapta un modelo preentrenado a una tarea específica mediante entrenamiento supervisado sobre datos del dominio objetivo. Sun et al. [43] caracterizaron los factores que inciden en su eficacia para clasificación de texto, entre ellos la tasa de aprendizaje, cuyo valor debe mantenerse reducido para preservar el conocimiento adquirido durante el preentrenamiento.

3.4.2. Aprendizaje multitarea

El aprendizaje multitarea [6] entrena un mismo modelo sobre varias tareas simultáneamente mediante una representación compartida. El beneficio procede de la transferencia inductiva: la información contenida en las señales de entrenamiento de una tarea actúa como sesgo que favorece la generalización en las demás.

Su aplicación requiere que las tareas aporten señales complementarias. La selección de una tarea auxiliar adecuada constituye un factor determinante del beneficio obtenido [36]: cuando una tarea puede derivarse de forma determinista de otra, no introduce información adicional en la representación compartida.

Cuando las tareas proceden de conjuntos de datos heterogéneos, que no comparten textos ni esquemas de etiquetado, el entrenamiento se organiza mediante muestreo alternante: cada lote procede de un único conjunto y solo interviene la función de pérdida correspondiente a

esa tarea [18]. El codificador compartido recibe actualizaciones derivadas de ambas, lo que constituye el mecanismo de transferencia.

Este procedimiento evita la necesidad de ponderar términos de pérdida que se suman en un mismo paso, problema para el cual se han propuesto métodos basados en la incertidumbre de cada tarea [15]. Bajo muestreo alternante el equilibrio queda determinado por la proporción con que se muestrea cada conjunto.

3.4.3. Estrategias de agrupamiento

El agrupamiento reduce la secuencia de vectores producida por el codificador a un único vector representativo del texto. Tres estrategias resultan pertinentes:

- Token de inicio: se emplea el vector de la primera posición, según la convención establecida en BERT [10].
- Promedio de embeddings: se calcula la media de los vectores de todos los tokens, excluyendo el relleno. Ha mostrado mayor robustez en secuencias extensas [49, 48].
- Agrupamiento por atención: una capa adicional aprende a ponderar la contribución de cada token antes de promediar [49].

La estructura seccional descrita en la sección 3.2.1 hace de esta decisión un asunto particularmente relevante en el dominio lírico, puesto que la repetición del estribillo concentra determinados términos y podría sesgar un promedio no ponderado.

3.5. Representación computacional de la emoción

3.5.1. Modelos dimensionales

El modelo circunflejo del afecto [37] representa las emociones como posiciones en un espacio continuo definido por dos ejes: la valencia, que expresa el carácter agradable o desagradable del estado afectivo, y la activación, que expresa su grado de intensidad fisiológica. La combinación de ambos ejes define cuatro cuadrantes, cada uno asociado a una familia de estados afectivos, según se representa en la Figura 3.1.

Se ha propuesto añadir una tercera dimensión, la dominancia, procedente del modelo tridimensional de Mehrabian y Russell [23], para distinguir estados próximos en el plano que difieren en el control percibido. No obstante, su incorporación incrementa la complejidad del modelo y la carga cognitiva de los anotadores, razón por la cual no suele emplearse en el

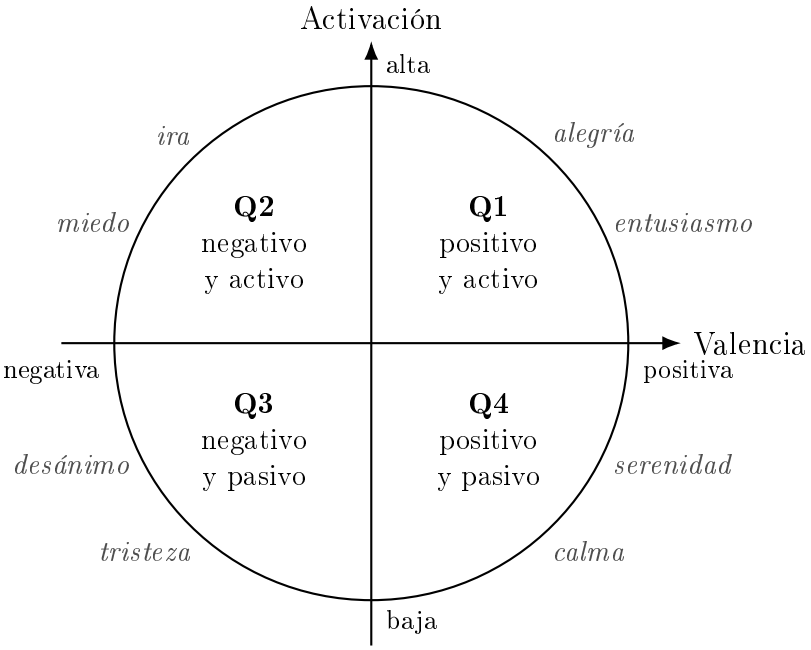


Figura 3.1: Modelo circunflejo del afecto y sus cuatro cuadrantes, adaptado de Russell [37].

reconocimiento emocional musical [22]. En esta tesis la representación dimensional se limita a valencia y activación, conforme a la anotación disponible en el corpus empleado.

3.5.2. Modelos categóricos y emociones consideradas

Frente a la representación dimensional, los modelos categóricos postulan un conjunto reducido de emociones básicas discretas. Ekman [11] propuso seis, argumentando su carácter universal a partir de evidencia transcultural, mientras que Plutchik [32] formuló una propuesta psicoevolutiva que amplía el conjunto e incorpora relaciones de intensidad y oposición entre categorías.

La tarea auxiliar de esta tesis adopta el esquema de seis categorías empleado por el corpus BRIGHTER [26], que sigue la propuesta de Ekman. Las categorías consideradas son las siguientes:

- Alegría: expresiones de felicidad, placer o satisfacción.
- Tristeza: expresiones de infelicidad, pesar o decepción.
- Ira: expresiones de frustración, irritación o furia.
- Miedo: expresiones de ansiedad, aprensión o temor.

- Sorpresa: expresiones de asombro ante un acontecimiento inesperado, que puede resultar agradable o desagradable.
- Asco: reacción ante algo ofensivo o desagradable.

El esquema contempla además una categoría neutra para los textos que no expresan ninguna de las anteriores, si bien el subconjunto en español no contiene instancias de esa clase [26]. Las anotaciones son multietiqueta: un mismo texto puede asociarse simultáneamente a varias categorías, lo que condiciona la elección de la función de pérdida y de las métricas de evaluación.

La Figura 3.2 presenta la distribución de las categorías emocionales en el conjunto de idiomas que componen dicho corpus. El subconjunto en español, identificado con el código `esp` y correspondiente a la variedad latinoamericana, dispone de las seis categorías y carece de instancias neutras.

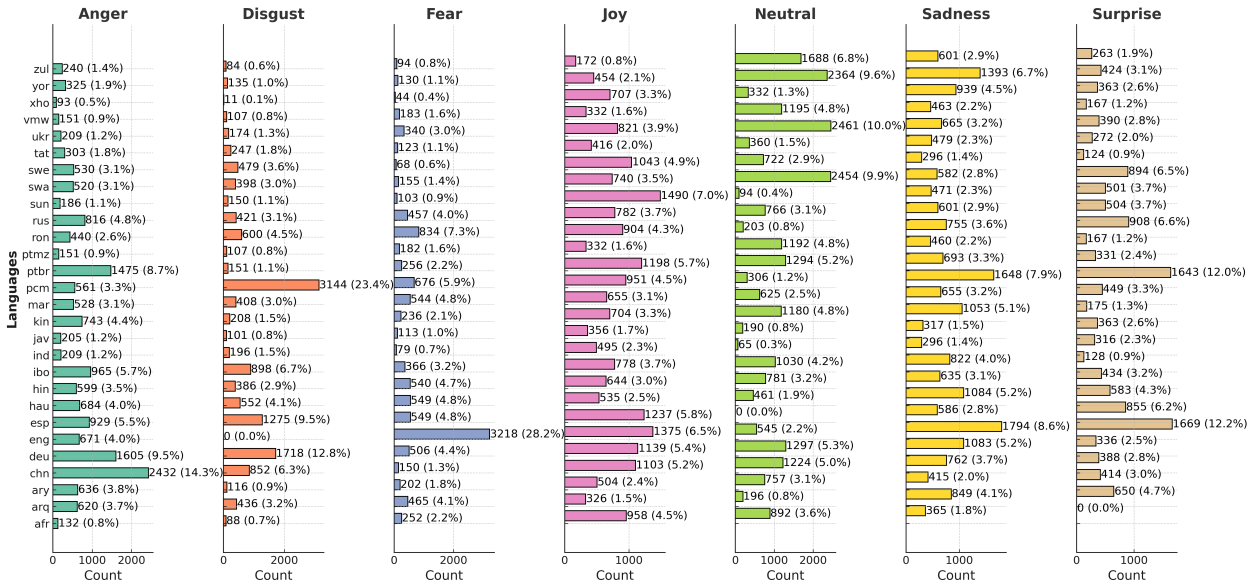


Figura 3.2: Distribución de las categorías emocionales anotadas en los conjuntos que integran BRIGHTER. Cada barra indica el número de instancias etiquetadas por emoción y su porcentaje. Tomado de Muhammad et al. [26].

Ambas representaciones aportan información distinta. Dos estados afectivos pueden ocupar posiciones próximas en el espacio dimensional y corresponder no obstante a categorías discretas diferentes: la ira y el miedo comparten valencia negativa y activación elevada, pero constituyen emociones distinguibles. Esta complementariedad justifica que las dos representaciones se empleen en tareas separadas dentro de la arquitectura propuesta.

3.5.3. Léxicos afectivos

Los léxicos afectivos asocian a cada palabra valores en las dimensiones emocionales, obtenidos mediante calificación humana. Warriner et al. [46] construyeron un recurso de 13915 lemas en inglés calificados en valencia, activación y dominancia; Redondo et al. [34] desarrollaron una adaptación al español calificada por hispanohablantes, y Mohammad [25] un recurso de mayor cobertura para el inglés.

Estos recursos no intervienen directamente en el modelo propuesto, pero constituyen el mecanismo mediante el cual se generaron las etiquetas del corpus lírico: los valores continuos de valencia y activación de MERGE se obtuvieron proyectando las etiquetas emocionales asignadas por editores profesionales sobre el espacio afectivo definido por el léxico de Warriner [22]. De ello se desprende una limitación que esta tesis asume explícitamente: dichos valores no proceden de calificación humana directa sobre cada canción, a diferencia de la asignación de cuadrantes.

3.6. Arquitectura propuesta

La arquitectura combina los elementos anteriores en un esquema de codificador compartido con dos cabezales de predicción, representado en la Figura 3.3.

El funcionamiento se resume en cuatro pasos. El muestreo alternante selecciona en cada iteración el corpus del que procede el lote, en una proporción fijada previamente. El codificador genera las representaciones contextuales del texto, con independencia de su procedencia. El agrupamiento sintetiza dichas representaciones en un único vector. Por último, ese vector alimenta el cabezal que corresponde al corpus de origen: el de regresión para los lotes líricos y el de clasificación para los del corpus auxiliar.

3.7. Evaluación

3.7.1. Métricas empleadas

La evaluación considera métricas distintas para cada tarea, dado que una corresponde a predicción de valores continuos y la otra a clasificación multietiqueta. El Cuadro 3.1 resume las métricas adoptadas.

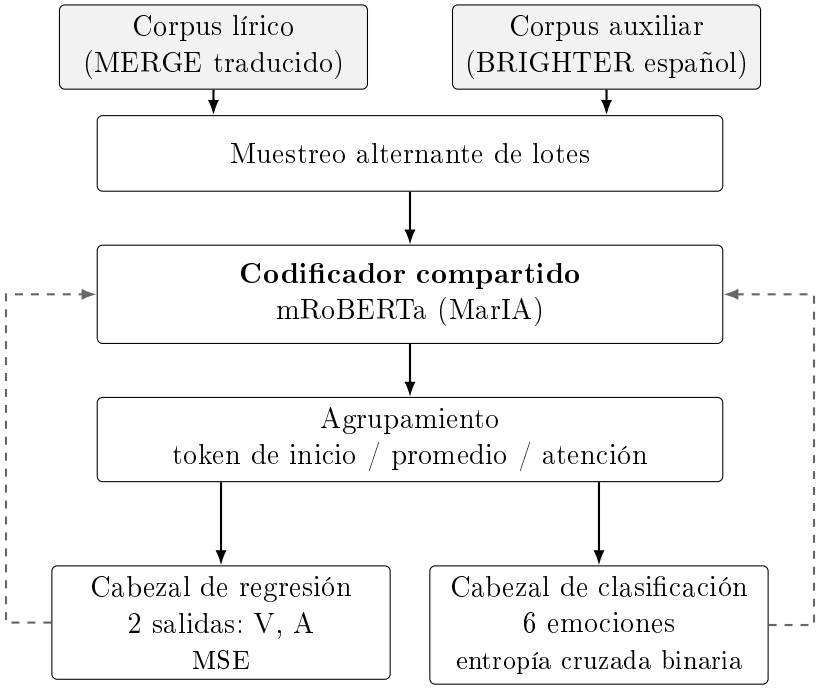


Figura 3.3: Arquitectura multitarea propuesta. Cada lote procede de un único corpus y activa únicamente el cabezal correspondiente; el codificador compartido recibe actualizaciones de ambas tareas, lo que constituye el mecanismo de transferencia.

Cuadro 3.1: Métricas de evaluación empleadas en cada tarea

Tarea	Métrica	Rango e interpretación	Propósito
Regresión (V, A)	Error cuadrático medio	$[0, \infty)$; menor es mejor	Cuantifica la magnitud promedio de la desviación respecto del valor de referencia
Regresión (V, A)	Correlación de Pearson	$[-1, 1]$; mayor es mejor	Mide si el modelo ordena correctamente las canciones a lo largo de cada dimensión
Regresión (V, A)	Coeficiente de determinación	$(-\infty, 1]$; mayor es mejor	Permite la comparación directa con la línea base publicada del corpus [22]
Clasificación	Exactitud	$[0, 1]$; mayor es mejor	Proporción de predicciones correctas; sensible al desbalance de clases
Clasificación	F1 macro	$[0, 1]$; mayor es mejor	Promedia el F1 por clase sin ponderar por frecuencia, de modo que las clases minoritarias pesan igual
Clasificación	F1 micro	$[0, 1]$; mayor es mejor	Agrega las decisiones de todas las clases antes de calcular la métrica, reflejando el rendimiento global

3.7.2. Justificación de las métricas

En la tarea de regresión, el error cuadrático medio y la correlación de Pearson aportan información complementaria. Un modelo puede presentar un error reducido y una correlación baja si predice valores próximos a la media del conjunto sin discriminar entre canciones; a la inversa, puede ordenarlas correctamente y mantener un sesgo sistemático que eleve el error. Reportar ambas evita conclusiones erróneas derivadas de considerar una sola.

El coeficiente de determinación se incorpora porque es la métrica que reporta la línea base del corpus empleado [22], de modo que su inclusión permite una comparación directa con los resultados publicados.

En la tarea de clasificación, la exactitud resulta insuficiente por sí sola: al ser sensible al desbalance de clases, un modelo puede alcanzar valores elevados prediciendo mayoritariamente la clase más frecuente [39]. La puntuación F1, media armónica de precisión y exhaustividad, corrige parcialmente esta limitación. En contextos multietiqueta admite dos formas de promediado, que responden a preguntas distintas: el promedio macro trata todas las categorías por igual, por lo que penaliza el mal rendimiento en emociones poco frecuentes, mientras que el micro refleja el rendimiento agregado sobre el total de decisiones [39]. Se reportan ambos por esa razón.

3.7.3. El acuerdo entre anotadores como referencia

En tareas cuya etiqueta de referencia procede de un juicio subjetivo, el rendimiento de un sistema automático no admite interpretación respecto de una exactitud perfecta. Dado que los propios anotadores discrepan entre sí, el grado de coincidencia que alcanzan establece un límite práctico para el rendimiento esperable.

El corpus auxiliar reporta esta información mediante el porcentaje de coincidencia de clase por mitades, procedimiento que divide repetidamente las anotaciones en subconjuntos aleatorios y mide con qué frecuencia cada instancia recibe la misma categoría en ambos; los valores obtenidos superan el sesenta por ciento en el conjunto de idiomas [26]. Los corpus líricos anotados por comités humanos reportan métricas equivalentes [8]. Los resultados de esta tesis se interpretan en relación con dichos valores.

3.8. Consideraciones finales

Los elementos expuestos configuran el fundamento de la propuesta: un objeto de análisis, la letra de canciones, cuya organización seccional y cuyo recurso sistemático a la significación indirecta condicionan el tratamiento computacional; un codificador basado en Transformer, preentrenado para el español, capaz de generar representaciones sensibles al contexto; un esquema de aprendizaje multitarea que transfiere conocimiento emocional entre dominios textuales mediante muestreo alternante; una representación emocional que combina las perspectivas dimensional y categórica; y un conjunto de métricas cuyos resultados se sitúan respecto del acuerdo alcanzado entre anotadores humanos. El capítulo siguiente detalla la forma en que estos elementos se articulan en la propuesta metodológica.

Capítulo 4

Propuesta

4.1. Consideraciones iniciales

El capítulo anterior presentó los fundamentos que sustentan esta tesis y la arquitectura que los articula. El presente capítulo describe de qué manera se lleva a cabo la propuesta: cómo se construyen los dos conjuntos de datos, cómo se configura el modelo, cómo se organiza el entrenamiento conjunto y qué experimentos permiten responder la pregunta de investigación formulada en el Capítulo 1.

Las decisiones que se exponen persiguen dos propósitos. El primero es que el efecto de la tarea auxiliar pueda aislarse de cualquier otro factor, para lo cual cada configuración multitarea se contrasta con una configuración equivalente que solo difiere en la ausencia de dicha tarea. El segundo es que el procedimiento resulte reproducible, de modo que se documentan los datos, las particiones, los hiperparámetros y las semillas empleadas.

4.2. Visión general de la propuesta

La propuesta se organiza en cinco fases sucesivas, representadas en la Figura 4.1. La primera construye el corpus lírico en español a partir de MERGE Lyrics Complete [22] mediante traducción automática. La segunda prepara el subconjunto en español de BRIGHTER [26], que aporta la tarea auxiliar. La tercera entrena el modelo bajo distintas configuraciones, variando la presencia de la tarea auxiliar y la estrategia de agrupamiento. La cuarta evalúa cada configuración con las métricas definidas en la Sección 3.7, y la quinta examina cualitativamente el comportamiento del modelo ante fragmentos líricos de interpretación compleja.

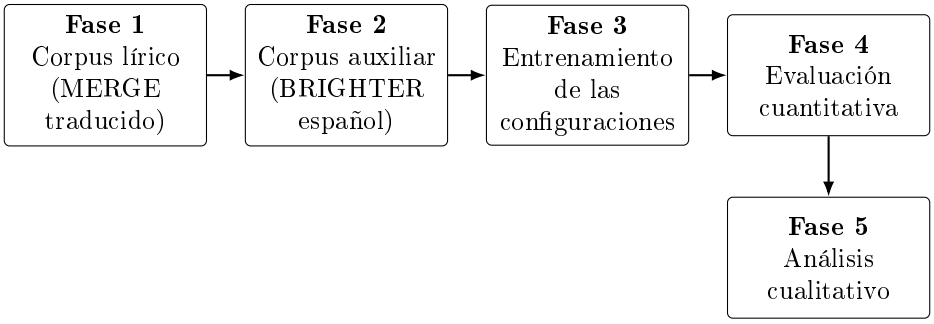


Figura 4.1: Fases de la propuesta. Las dos primeras construyen los conjuntos de datos; la tercera entrena las configuraciones experimentales; las dos últimas analizan los resultados.

4.3. Construcción de los conjuntos de datos

4.3.1. Corpus lírico: MERGE Lyrics Complete

La tarea principal emplea la variante *Lyrics Complete* de MERGE [22], compuesta por 2568 letras en inglés distribuidas entre los cuatro cuadrantes de Russell: 600 en el primero, 710 en el segundo, 621 en el tercero y 637 en el cuarto. Se prefiere esta variante a la balanceada, que reduce cada cuadrante a 600 letras, porque conserva 168 ejemplos adicionales y sus autores reportan que el desbalance tiene un impacto reducido en los resultados [22].

De cada letra se emplean tres elementos: el texto, los valores continuos de valencia y activación, que constituyen la variable objetivo de la regresión, y el cuadrante validado manualmente, que no interviene en el entrenamiento pero se utiliza en la comparación con la línea base publicada (Sección 4.6.2).

Las particiones de entrenamiento, validación y prueba se toman de la configuración 70-15-15 distribuida con el propio corpus, que sus autores proponen como perfil principal de referencia [22]. No se generan particiones propias, de modo que los resultados de esta tesis resulten comparables con los publicados.

4.3.2. Traducción automática al español

Dado que no existe un corpus lírico en español con anotaciones emocionales equivalentes, las letras se traducen al español mediante traducción automática, procedimiento que los autores de MERGE plantean como línea de trabajo futuro [22]. Se emplea el modelo NLLB-200 en su variante destilada de 600 millones de parámetros [28], sistema de traducción neuronal de código abierto. Su elección responde a tres razones: puede ejecutarse localmente sin depender de servicios comerciales, lo que garantiza la reproducibilidad; su versión es fija, de modo que la misma entrada produce siempre la misma traducción; y su licencia permite el

uso con fines de investigación.

La traducción se realiza verso por verso y no sobre la letra completa. Esta decisión obedece a dos motivos. Por un lado, los sistemas de traducción neuronal degradan su calidad ante entradas extensas, y una letra completa supera con frecuencia la longitud para la que fueron entrenados. Por otro, traducir cada verso por separado conserva la segmentación original del texto, y con ella la estructura de versos y estribillos descrita en la Sección 3.2.1. Los versos repetidos se traducen una sola vez y se reutiliza su traducción, lo que garantiza que un mismo estribillo reciba siempre el mismo texto en español.

Las etiquetas de valencia, activación y cuadrante se heredan sin modificación de la letra original. Este procedimiento asume que la traducción preserva el contenido emocional del texto, supuesto que no se cumple en todos los casos: los juegos de palabras, las expresiones idiomáticas y la rima pueden perderse o alterarse. Se trata de una limitación declarada de la tesis, cuyo alcance se estima mediante el control de calidad descrito a continuación.

4.3.3. Control de calidad de la traducción

Para estimar en qué medida la traducción preserva el contenido emocional, se selecciona una muestra aleatoria estratificada de 100 letras, 25 por cuadrante, que se revisa manualmente comparando el original con su traducción. Cada letra se califica según tres criterios:

- **Fidelidad semántica**: si la traducción conserva el significado del original.
- **Conservación del tono emocional**: si la emoción que transmite la traducción corresponde al cuadrante asignado a la letra original.
- **Errores graves**: presencia de fragmentos sin traducir, texto repetido de forma anómala u omisiones de versos completos.

Las letras de la muestra que presenten errores graves se corrigen o se excluyen, y la proporción observada de cada tipo de error se reporta junto con los resultados. Este procedimiento no garantiza la calidad de todo el corpus, pero permite cuantificar la limitación en lugar de asumirla sin verificación, en coherencia con el criterio adoptado en la Sección 1.3.

4.3.4. Corpus auxiliar: subconjunto en español de BRIGHTER

La tarea auxiliar emplea el subconjunto en español de BRIGHTER [26], correspondiente a la variedad latinoamericana. Está compuesto por 3875 comentarios de canales de YouTube de noticias, entretenimiento y educación, anotados por un grupo de 12 hablantes nativos, con

cinco anotaciones por instancia. Cada texto se asocia a una o varias de las seis emociones descritas en la Sección 3.5.2, y el subconjunto no contiene instancias neutras.

Se emplean las particiones oficiales: 1996 instancias de entrenamiento, 184 de validación y 1695 de prueba [26]. Las de entrenamiento alimentan la tarea auxiliar; las de validación se emplean para fijar el umbral de decisión del cabezal de clasificación, y las de prueba para medir el rendimiento de dicho cabezal al final del entrenamiento.

El Cuadro 4.1 resume las características de ambos conjuntos.

Cuadro 4.1: Conjuntos de datos empleados en la propuesta

	MERGE Lyrics Complete	**BRIGHTER (español)**
Función	Tarea principal	Tarea auxiliar
Tipo de texto	Letras de canciones	Comentarios de YouTube
Idioma	Inglés, traducido al español	Español latinoamericano nativo
Instancias	2568	3875
Particiones	70-15-15 oficial	1996 / 184 / 1695 oficial
Etiqueta	Valencia y activación continuas	Seis emociones, multietiqueta
Tipo de tarea	Regresión	Clasificación multietiqueta
Validación de etiquetas	Cuadrante validado por ocho evaluadores; V y A derivadas de léxico	Cinco anotadores nativos por instancia

4.3.5. Preprocesamiento y tokenización

Ambos corpus reciben el mismo tratamiento previo. Se normalizan los espacios en blanco, se eliminan las líneas vacías consecutivas y se descartan las anotaciones ajenas a la letra que aparecen en algunas fuentes, como marcas de sección entre corchetes. No se eliminan palabras vacías ni signos de puntuación, ni se convierte el texto a minúsculas, puesto que el codificador fue preentrenado sobre texto sin normalizar y estos elementos aportan información contextual.

La tokenización emplea el tokenizador propio de mRoBERTa. Las secuencias se truncan a 512 tokens, longitud máxima admitida por el modelo [12]. La proporción de letras que exceden ese límite se calcula y se reporta, dado que el truncamiento descarta el final de la letra y, con él, posibles repeticiones del estribillo. El tratamiento jerárquico de secuencias extensas queda fuera del alcance de esta tesis, según lo expuesto en la Sección 1.2.

4.4. Configuración del modelo

4.4.1. Codificador

El codificador es mRoBERTa en su variante base, distribuida públicamente con el identificador `PlanTL-GOB-ES/roberta-base-bne` [12]. Todos sus parámetros se actualizan durante el entrenamiento, sin congelar ninguna capa. Para una secuencia de entrada de n tokens, el codificador produce una secuencia de vectores contextuales $\mathbf{H} = (\mathbf{h}_1, \ldots, \mathbf{h}_n)$, con $\mathbf{h}_i \in \mathbb{R}^{768}$.

4.4.2. Estrategias de agrupamiento

El agrupamiento reduce la secuencia $\mathbf{H}$ a un único vector $\mathbf{z} \in \mathbb{R}^{768}$. Se evalúan las tres estrategias presentadas en la Sección 3.4.3. Sea $m_i \in \{0, 1\}$ la máscara de atención, que vale 1 para los tokens reales y 0 para los de relleno.

A. Token de inicio. Se emplea el vector de la primera posición, correspondiente al token especial de inicio de secuencia [10]:

$$\mathbf{z}_{\mathrm{A}} = \mathbf{h}_1. \tag{4.1}$$

B. Promedio de embeddings. Se calcula la media de los vectores de los tokens reales, excluyendo el relleno [49]:

$$\mathbf{z}_{\mathrm{B}} = \frac{\sum_{i=1}^{n} m_i \, \mathbf{h}_i}{\sum_{i=1}^{n} m_i}. \tag{4.2}$$

C. Agrupamiento por atención. Una capa lineal entrenable asigna a cada token una puntuación, que se normaliza mediante la función softmax sobre los tokens reales para obtener un peso [49]:

$$s_i = \mathbf{w}^{\top} \mathbf{h}_i + b, \qquad \alpha_i = \frac{m_i \exp(s_i)}{\sum_{j=1}^{n} m_j \exp(s_j)}, \qquad \mathbf{z}_{\mathrm{C}} = \sum_{i=1}^{n} \alpha_i \, \mathbf{h}_i, \tag{4.3}$$

donde $\mathbf{w} \in \mathbb{R}^{768}$ y $b \in \mathbb{R}$ se aprenden junto con el resto del modelo. A diferencia del promedio, esta estrategia permite que el modelo reduzca el peso de los términos que se repiten en el estribillo, si ello resulta beneficioso para la tarea.

La estrategia de agrupamiento es común a ambas tareas: el mismo vector $\mathbf{z}$ alimenta el cabezal que corresponda según el origen del lote.

4.4.3. Cabezales de predicción y funciones de pérdida

Sobre el vector agrupado se aplica una capa de abandono (*dropout*) con probabilidad 0,1 y, a continuación, el cabezal correspondiente.

Cabezal de regresión. Una capa lineal produce dos valores, la valencia y la activación predichas:

$$(\hat{v}, \hat{a}) = \mathbf{W}_r \, \mathbf{z} + \mathbf{b}_r, \qquad \mathbf{W}_r \in \mathbb{R}^{2\times 768}. \tag{4.4}$$

La función de pérdida es el error cuadrático medio, promediado sobre las dos dimensiones y sobre las B letras del lote:

$$\mathcal{L}_{\text{reg}} = \frac{1}{2B} \sum_{k=1}^{B} \left[(\hat{v}_k - v_k)^2 + (\hat{a}_k - a_k)^2 \right]. \tag{4.5}$$

Cabezal de clasificación. Una capa lineal produce seis valores, uno por emoción, que la función sigmoide σ transforma en probabilidades independientes:

$$\hat{\mathbf{p}} = \sigma(\mathbf{W}_c \, \mathbf{z} + \mathbf{b}_c), \qquad \mathbf{W}_c \in \mathbb{R}^{6\times 768}. \tag{4.6}$$

Dado que las anotaciones son multietiqueta, se emplea la sigmoide en lugar de la función softmax: cada emoción se decide de forma independiente y un texto puede activar varias a la vez. La función de pérdida es la entropía cruzada binaria promediada sobre las seis emociones y los textos del lote:

$$\mathcal{L}_{\text{cls}} = -\frac{1}{6B} \sum_{k=1}^{B} \sum_{e=1}^{6} \left[y_{k,e} \log \hat{p}_{k,e} + (1 - y_{k,e}) \log(1 - \hat{p}_{k,e}) \right]. \tag{4.7}$$

En la inferencia, una emoción se considera presente cuando su probabilidad supera un umbral τ, fijado inicialmente en 0,5 y ajustado sobre la partición de validación de BRIGHTER.

El cabezal de clasificación no predice cuadrantes de Russell. Dado que el cuadrante es función determinista de la valencia y la activación, una tarea que lo predijera no aportaría información adicional a la representación compartida [36], según lo expuesto en la Sección 3.4.2.

4.5. Procedimiento de entrenamiento

4.5.1. Muestreo alternante

El entrenamiento conjunto sigue el esquema de muestreo alternante de MT-DNN [18]. En cada iteración se elige el corpus del que procede el lote: MERGE con probabilidad p y BRIGHTER con probabilidad $1-p$. Cada lote contiene ejemplos de un único corpus y activa únicamente la función de pérdida que le corresponde, de modo que nunca se mezclan en un mismo paso etiquetas de distinta naturaleza. El Algoritmo 1 describe el procedimiento.

Algoritmo 1 Entrenamiento multitarea mediante muestreo alternante

Entrada: Corpus lírico $\mathcal{D}_L$, corpus auxiliar $\mathcal{D}_A$, proporción p, número de épocas E

para época $= 1$ **hasta** E **hacer**
  Barajar $\mathcal{D}_L$ y $\mathcal{D}_A$ y dividirlos en lotes
  $T \leftarrow \lceil N_L/(p \cdot B) \rceil$ ▷ pasos por época
  para $t = 1$ **hasta** T **hacer**
    Tomar $u \sim \mathcal{U}(0,1)$
    si $u < p$ **entonces**
      Tomar el siguiente lote de $\mathcal{D}_L$
      $\mathbf{z} \leftarrow$ Agrupar(Codificador(lote))
      $\mathcal{L} \leftarrow \mathcal{L}_{\text{reg}}$(CabezalRegresión($\mathbf{z}$), (v, a))
    si no
      Tomar el siguiente lote de $\mathcal{D}_A$
      $\mathbf{z} \leftarrow$ Agrupar(Codificador(lote))
      $\mathcal{L} \leftarrow \mathcal{L}_{\text{cls}}$(CabezalClasificación($\mathbf{z}$), $\mathbf{y}$)
    fin si
    Retropropagar $\mathcal{L}$ y actualizar los parámetros
  fin para
  Evaluar sobre la validación de $\mathcal{D}_L$ y conservar el mejor modelo
fin para

En el algoritmo, N_L es el número de letras de entrenamiento y B el tamaño de lote. El número de pasos por época se define de modo que, en promedio, cada letra de entrenamiento se procese una vez por época; cuando uno de los corpus agota sus lotes, se vuelve a barajar y se continúa desde su inicio.

La proporción de partida es $p = 0{,}7$, es decir, siete de cada diez lotes proceden del corpus lírico. Se privilegia la tarea principal porque es la que se pretende mejorar, mientras que la tarea auxiliar actúa como fuente de conocimiento complementario. Bajo este esquema no se requiere ponderar las funciones de pérdida [15], puesto que nunca se suman en un mismo paso: el equilibrio entre tareas queda determinado por p.

En las configuraciones de tarea única, el procedimiento es el mismo con $p = 1$: todos los

lotes proceden del corpus lírico y el cabezal de clasificación no se utiliza.

4.5.2. Hiperparámetros

El Cuadro 4.2 recoge los hiperparámetros empleados. Los valores de partida siguen las recomendaciones de Sun et al. [43] para el ajuste fino de codificadores de la familia BERT, en particular una tasa de aprendizaje reducida que preserve el conocimiento adquirido durante el preentrenamiento. Todas las configuraciones comparten los mismos valores, de modo que las diferencias observadas entre ellas no puedan atribuirse a un ajuste desigual.

Cuadro 4.2: Hiperparámetros de entrenamiento

Hiperparámetro	**Valor**
Optimizador	AdamW [21]
Tasa de aprendizaje	2×10^{-5}
Decaimiento de pesos	0,01
Calendario de la tasa	Calentamiento lineal (10 % de los pasos) y decaimiento lineal
Tamaño de lote	16
Número de épocas	4
Longitud máxima de secuencia	512 tokens
Abandono en los cabezales	0,1
Proporción de muestreo p	0,7 (multitarea) / 1,0 (tarea única)
Umbral de clasificación τ	0,5, ajustado en validación
Semillas	3 por configuración

4.5.3. Selección del modelo y reproducibilidad

Al final de cada época se evalúa el modelo sobre la partición de validación del corpus lírico, y se conserva el estado con menor error cuadrático medio promedio de valencia y activación. El criterio se basa exclusivamente en la tarea principal, incluso en las configuraciones multitarea, porque es la tarea cuyo rendimiento se pretende mejorar. La partición de prueba no se consulta en ningún momento del entrenamiento ni de la selección.

Cada configuración se entrena con tres semillas aleatorias distintas, que determinan la inicialización de los cabezales, el orden de los lotes y la secuencia de elecciones del muestreo alternante. Los resultados se reportan como media y desviación estándar sobre las tres ejecuciones, lo que permite distinguir las diferencias atribuibles a la configuración de las que proceden de la variabilidad del entrenamiento.

4.6. Diseño experimental

4.6.1. Configuraciones evaluadas

El diseño experimental cruza dos factores: la presencia de la tarea auxiliar (tarea única o multitarea) y la estrategia de agrupamiento (A, B o C). De ello resultan seis configuraciones, recogidas en el Cuadro 4.3, que con tres semillas cada una suman dieciocho entrenamientos.

Cuadro 4.3: Configuraciones experimentales

Configuración	Entrenamiento	Agrupamiento	Semillas
TU-A	Tarea única (MERGE)	Token de inicio	3
TU-B	Tarea única (MERGE)	Promedio	3
TU-C	Tarea única (MERGE)	Atención	3
MT-A	Multitarea (MERGE + BRIGHTER)	Token de inicio	3
MT-B	Multitarea (MERGE + BRIGHTER)	Promedio	3
MT-C	Multitarea (MERGE + BRIGHTER)	Atención	3

Sobre estas configuraciones se realizan tres comparaciones.

Comparación 1: multitarea frente a tarea única. Para cada estrategia de agrupamiento se compara la configuración multitarea con su equivalente de tarea única (MT-A frente a TU-A, y así sucesivamente). Ambas comparten codificador, agrupamiento, hiperparámetros, particiones y semillas, y solo difieren en la presencia de la tarea auxiliar, por lo que cualquier diferencia en el rendimiento puede atribuirse a ella. Esta comparación responde directamente la pregunta de investigación, y se mide con las métricas de regresión sobre la partición de prueba del corpus lírico.

Comparación 2: frente a la línea base publicada. La mejor configuración se contrasta con la línea base reportada por los autores de MERGE para letras: F1 de 71.40 % en la clasificación de cuadrantes y coeficientes de determinación de 0.366 en activación y 0.569 en valencia [22]. El procedimiento se detalla en la Sección 4.6.2.

Comparación 3: estrategias de agrupamiento. Las tres estrategias se comparan entre sí, tanto en tarea única como en multitarea, para determinar cuál representa mejor el contenido emocional de un texto lírico y si su efecto depende de la presencia de la tarea auxiliar.

Adicionalmente, en las configuraciones multitarea se reporta el rendimiento del cabezal de clasificación sobre la partición de prueba de BRIGHTER, mediante exactitud, F1 macro

y F1 micro. Este resultado no responde la pregunta de investigación, pero permite verificar que la tarea auxiliar se aprende efectivamente y situar su rendimiento respecto del acuerdo entre anotadores reportado para el corpus [26].

4.6.2. Comparación con la línea base publicada

La línea base de MERGE reporta su F1 sobre la clasificación de cuadrantes, mientras que el modelo propuesto predice valores continuos de valencia y activación. Para que ambas cifras sean comparables, el cuadrante se deriva del signo de los valores predichos, conforme a la definición del modelo circunflejo representada en la Figura 3.1:

$$\hat{q} = \begin{cases} \text{Q1} & \text{si } \hat{v} \geq 0 \text{ y } \hat{a} \geq 0, \\ \text{Q2} & \text{si } \hat{v} < 0 \text{ y } \hat{a} \geq 0, \\ \text{Q3} & \text{si } \hat{v} < 0 \text{ y } \hat{a} < 0, \\ \text{Q4} & \text{si } \hat{v} \geq 0 \text{ y } \hat{a} < 0. \end{cases} \tag{4.8}$$

El cuadrante derivado se compara con el cuadrante validado manualmente de cada letra, y sobre esa comparación se calculan la exactitud y el F1 de la clasificación en cuatro clases, junto con la matriz de confusión correspondiente. Los coeficientes de determinación de valencia y activación se comparan directamente.

Esta comparación debe interpretarse con cautela por dos razones. La primera es que la línea base opera sobre las letras originales en inglés y el modelo propuesto sobre su traducción al español, de modo que las diferencias pueden deberse en parte a la traducción. La segunda es que el modelo propuesto no fue entrenado para clasificar cuadrantes, sino para predecir valores continuos, y el cuadrante se obtiene como subproducto. Por esta razón, la comparación principal de la tesis es la primera, en la que ambos modelos operan sobre los mismos datos traducidos.

4.6.3. Análisis estadístico

Para determinar si la diferencia entre una configuración multitarea y su equivalente de tarea única es consistente, y no producto del azar, se aplica la prueba de remuestreo pareado (*paired bootstrap*) [4] sobre las predicciones de la partición de prueba. El procedimiento genera 1000 muestras con reemplazo del conjunto de prueba, calcula en cada una la diferencia de la métrica entre ambas configuraciones y estima a partir de ellas un intervalo de confianza del 95 %. Una diferencia se considera significativa cuando dicho intervalo no contiene el cero.

4.7. Análisis cualitativo

El análisis cuantitativo indica cuánto acierta el modelo, pero no en qué tipo de textos lo hace. Para caracterizar su comportamiento en los casos propios del dominio lírico se realiza un análisis cualitativo sobre la partición de prueba, organizado en tres pasos.

1. **Selección de fragmentos.** Se seleccionan letras que presenten lenguaje figurado o ambigüedad contextual, en particular aquellas en las que el sentido emocional no se deduce del significado literal de las palabras (Sección 3.2.2), y aquellas cuyo cuadrante derivado difiere del cuadrante validado.

2. **Contraste entre configuraciones.** Para cada fragmento se comparan las predicciones de la mejor configuración multitarea y de su equivalente de tarea única, con el fin de identificar los casos en que la tarea auxiliar modifica la interpretación del modelo.

3. **Inspección de los pesos de atención.** En las configuraciones con agrupamiento por atención (C), se examinan los pesos α_i asignados a cada token, para determinar qué versos concentran la atención del modelo y si el estribillo recibe un peso desproporcionado.

Los errores observados se clasifican según su posible origen: limitaciones de la traducción, lenguaje figurado no interpretado, truncamiento de la letra o ambigüedad de la propia etiqueta. Esta clasificación permite separar los errores atribuibles al modelo de los que proceden de los datos.

4.8. Entorno de implementación

La propuesta se implementa en Python, empleando PyTorch [31] para la definición y el entrenamiento del modelo, y la biblioteca Transformers de Hugging Face [47] para cargar mRoBERTa, su tokenizador y el modelo de traducción. Las métricas se calculan con scikit-learn y SciPy. El entrenamiento se ejecuta en Google Colab sobre una unidad de procesamiento gráfico, dado que el ajuste fino de un codificador de este tamaño no resulta viable en procesador convencional.

El código, las configuraciones de cada experimento y las semillas se mantienen en un repositorio de control de versiones, de modo que cualquier resultado reportado pueda reproducirse a partir de la configuración que lo produjo. Los corpus no se incluyen en el repositorio, dado que su distribución está sujeta a las licencias de sus autores, pero se documenta el procedimiento para obtenerlos y transformarlos.

4.9. Amenazas a la validez

Se identifican cuatro factores que pueden afectar la validez de las conclusiones, junto con la forma en que la propuesta los aborda.

- **Calidad de la traducción.** Las etiquetas se heredan de la letra original, y la traducción puede alterar su contenido emocional. Se mitiga mediante el control de calidad de la Sección 4.3.3, que cuantifica el alcance del problema.
- **Validez de las etiquetas continuas.** Los valores de valencia y activación de MERGE proceden de una proyección automática basada en un léxico y no de calificación humana directa [22]. Se mitiga contrastando el cuadrante derivado de las predicciones con el cuadrante validado manualmente, que sí cuenta con verificación humana.
- **Diferencia de dominio y de variedad.** El corpus auxiliar procede de redes sociales y de español latinoamericano, mientras que el corpus lírico procede de una traducción automática y mRoBERTa fue preentrenado mayoritariamente sobre español peninsular. Estas diferencias pueden limitar la transferencia, y se consideran al interpretar los resultados.
- **Variabilidad del entrenamiento.** El ajuste fino de codificadores de este tipo presenta variaciones entre ejecuciones con distinta semilla. Se mitiga entrenando cada configuración con tres semillas y aplicando la prueba de remuestreo pareado.

4.10. Consideraciones finales

Este capítulo ha descrito la propuesta en cinco fases: la construcción del corpus lírico en español mediante traducción verso por verso de MERGE Lyrics Complete, con un control de calidad que cuantifica sus limitaciones; la preparación del subconjunto en español de BRIGHTER como tarea auxiliar; el entrenamiento de seis configuraciones que cruzan la presencia de la tarea auxiliar con tres estrategias de agrupamiento, mediante muestreo alternante y con hiperparámetros comunes; la evaluación cuantitativa con las métricas definidas en el Capítulo 3; y el análisis cualitativo de los casos propios del dominio lírico.

El elemento central del diseño es la comparación entre cada configuración multitarea y su equivalente de tarea única, que solo difieren en la presencia de la tarea auxiliar y permiten, por tanto, aislar su efecto. El capítulo siguiente presenta los resultados obtenidos al aplicar este procedimiento.

Bibliografía

[1] Yudhik Agrawal, Ramaguru Guru Ravi Shanker, and Vinoo Alluri. Transformer-based approach towards music emotion recognition from lyrics. In *Advances in Information Retrieval (ECIR)*, pages 167–175. Springer, 2021.

[2] Tina Babu, Rekha R. Nair, and A. Geetha. Emotion-aware music recommendation system: Enhancing user experience through real-time emotional context. *arXiv preprint arXiv:2311.10796*, 2023.

[3] Gonçalo T. Barradas and Laura S. Sakka. When words matter: A cross-cultural perspective on lyrics and their relationship to musical emotions. *Psychology of Music*, 50(2):650–669, 2022.

[4] Taylor Berg-Kirkpatrick, David Burkett, and Dan Klein. An empirical investigation of statistical significance in NLP. In *Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning (EMNLP-CoNLL)*, pages 995–1005, 2012.

[5] T. Bernal-Beltrán, M. A. Paredes-Valverde, M. d. P. Salas-Zárate, J. A. García-Díaz, and R. Valencia-García. Sentiment analysis in mexican spanish: A comparison between fine-tuning and in-context learning with large language models. *Future Internet*, 17(10):445, 2025.

[6] Rich Caruana. Multitask learning. *Machine Learning*, 28(1):41–75, 1997.

[7] José Cañete, Gabriel Chaperon, Rodrigo Fuentes, Jou-Hui Ho, Hojin Kang, and Jorge Pérez. Spanish pre-trained BERT model and evaluation data. In *PML4DC at ICLR 2020*, 2020.

[8] Shay Dahary, Avi Edana, Alexander Apartsin, and Yehudit Aperstein. From joy to fear: A benchmark of emotion estimation in pop song lyrics. *arXiv preprint arXiv:2509.05617*, 2025.

[9] Rémi Delbouys, Romain Hennequin, Francesco Piccoli, Jimena Royo-Letelier, and Manuel Moussallam. Music mood detection based on audio and lyrics with deep neural net. *arXiv preprint arXiv:1809.07276*, 2018.

[10] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, pages 4171–4186, 2019.

[11] Paul Ekman. An argument for basic emotions. *Cognition and Emotion*, 6(3-4):169–200, 1992.

[12] Asier Gutiérrez-Fandiño, Jordi Armengol-Estapé, Marc Pàmies, Joan Llop-Palao, Joaquín Silveira-Ocampo, Casimiro Pio Carrino, Carme Armentano-Oller, Carlos Rodriguez-Penagos, Aitor Gonzalez-Agirre, and Marta Villegas. MarIA: Spanish language models. *arXiv preprint arXiv:2107.07253*, 2022. v5.

[13] International Federation of the Phonographic Industry. Global music report 2026. Technical report, IFPI, London, 2026.

[14] Patrik N. Juslin and Petri Laukka. Expression, perception, and induction of musical emotions: A review and a questionnaire study of everyday listening. *Journal of New Music Research*, 33(3):217–238, 2004.

[15] Alex Kendall, Yarin Gal, and Roberto Cipolla. Multi-task learning using uncertainty to weigh losses for scene geometry and semantics. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.

[16] Minho Kim and Hyuk-Chul Kwon. Lyrics-based emotion classification using feature selection by partial syntactic analysis. In *2011 IEEE 23rd International Conference on Tools with Artificial Intelligence (ICTAI)*, pages 527–532. IEEE, 2011.

[17] George Lakoff and Mark Johnson. *Metaphors We Live By*. University of Chicago Press, Chicago, 1980.

[18] Xiaodong Liu, Pengcheng He, Weizhu Chen, and Jianfeng Gao. Multi-task deep neural networks for natural language understanding. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 4487–4496, 2019.

[19] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.

[20] Rashini Liyanarachchi, Frank Tran, Md Mahmudul Hasan, Aditya Joshi, and Erik Meijering. A hybrid framework for song lyric annotation based on human-LLM alignment. *arXiv preprint arXiv:2606.29273*, 2026.

[21] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.

[22] Pedro Lima Louro, Hugo Redinho, Tiago Filipe Rodrigues Ribeiro, Ricardo Santos, Ricardo Malheiro, Renato Panda, and Rui Pedro Paiva. MERGE: A bimodal audio-lyrics dataset for static music emotion recognition. *IEEE Transactions on Affective Computing*, 2026. DOI: 10.1109/TAFFC.2026.3668037.

[23] Albert Mehrabian and James A. Russell. *An Approach to Environmental Psychology.* MIT Press, Cambridge, MA, 1974.

[24] Rada Mihalcea and Carlo Strapparava. Lyrics, music, and emotions. In *Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning (EMNLP-CoNLL)*, pages 590–599, Jeju Island, Korea, 2012. Association for Computational Linguistics.

[25] Saif M. Mohammad. Obtaining reliable human ratings of valence, arousal, and dominance for 20,000 English words. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 174–184, 2018.

[26] Shamsuddeen Hassan Muhammad, Nedjma Ousidhoum, Idris Abdulmumin, Jan Philip Wahle, Terry Ruas, Meriem Beloucif, Christine de Kock, Nirmal Surange, Daniela Teodorescu, Ibrahim Said Ahmad, David Ifeoluwa Adelani, Alham Fikri Aji, Felermino D. M. A. Ali, Vladimir Araujo, Rodrigo Tufiño, Alexander Panchenko, Yi Zhou, and Saif M. Mohammad. BRIGHTER: BRIdging the gap in human-annotated textual emotion recognition datasets for 28 languages. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 8895–8916, Vienna, Austria, 2025.

[27] Shamsuddeen Hassan Muhammad, Nedjma Ousidhoum, Idris Abdulmumin, Seid Muhie Yimam, Jan Philip Wahle, Terry Ruas, Meriem Beloucif, Christine De Kock, Tadesse Destaw Belay, Ibrahim Said Ahmad, Nirmal Surange, Daniela Teodorescu, David Ifeoluwa Adelani, Alham Fikri Aji, Felermino D. M. A. Ali, Oana Ignat, Alexander Panchenko, Yi Zhou, Saif M. Mohammad, et al. SemEval-2025 task 11: Bridging the gap in text-based emotion detection. *arXiv preprint arXiv:2503.07269*, 2025.

[28] NLLB Team, Marta R. Costa-jussà, James Cross, et al. No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv:2207.04672*, 2022.

[29] Drew Nobile. Teleology in verse–prechorus–chorus form, 1965–1990. *Music Theory Online*, 28(3), 2022.

[30] Raghavendra Pappagari, Piotr Żelasko, Jesús Villalba, Yishay Carmiel, and Najim Dehak. Hierarchical transformers for long document classification. In *2019 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU)*, pages 838–844. IEEE, 2019.

[31] Adam Paszke, Sam Gross, Francisco Massa, et al. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 32, 2019.

[32] Robert Plutchik. A general psychoevolutionary theory of emotion. In Robert Plutchik and Henry Kellerman, editors, *Theories of Emotion*, pages 3–33. Academic Press, 1980.

[33] Sebastian Raschka. MusicMood: Predicting the mood of music from song lyrics using machine learning. *arXiv preprint arXiv:1611.00138*, 2016.

[34] Jaime Redondo, Isabel Fraga, Isabel Padrón, and Montserrat Comesaña. The Spanish adaptation of ANEW (affective norms for English words). *Behavior Research Methods*, 39(3):600–605, 2007.

[35] V. R. Revathy, Anitha S. Pillai, and Fatemah Daneshfar. LyEmoBERT: Classification of lyrics' emotion and recommendation using a pre-trained model. *Procedia Computer Science*, 218:1196–1208, 2023.

[36] Sebastian Ruder. An overview of multi-task learning in deep neural networks. *arXiv preprint arXiv:1706.05098*, 2017.

[37] James A. Russell. A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6):1161–1178, 1980.

[38] M. Santana, C. Lins de Lima, A. Sarmento, et al. Affective computing in the context of music therapy: A systematic review. *Research, Society and Development*, 10(15):e392101522844, 2021.

[39] Marina Sokolova and Guy Lapalme. A systematic analysis of performance measures for classification tasks. *Information Processing and Management*, 45(4):427–437, 2009.

[40] Yingjin Song and Daniel Beck. Modelling emotion dynamics in song lyrics with state space models. *Transactions of the Association for Computational Linguistics (TACL)*, 2023.

[41] Alvin Subakti, Hendri Murfi, and Nora Hariadi. Exploring the effectiveness of BERT using different pooling strategies for news classification. *Journal of Big Data*, 2023.

[42] Jay Summach. The structure, function, and genesis of the prechorus. *Music Theory Online*, 17(3), 2011.

[43] Chi Sun, Xipeng Qiu, Yige Xu, and Xuanjing Huang. How to fine-tune BERT for text classification? *arXiv preprint arXiv:1905.05583*, 2019.

[44] Alejandro Vaca Serrano, Guillem García Subies, Helena Montoro Zamorano, Nuria Aldama García, Doaa Samy, David Betancur Sánchez, Antonio Moreno-Sandoval, Marta Guerrero Nieto, and Álvaro Barbero Jiménez. RigoBERTa: A state-of-the-art language model for spanish. *arXiv preprint arXiv:2205.10233*, 2022.

[45] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

[46] Amy Beth Warriner, Victor Kuperman, and Marc Brysbaert. Norms of valence, arousal, and dominance for 13,915 English lemmas. *Behavior Research Methods*, 45(4):1191–1207, 2013.

[47] Thomas Wolf, Lysandre Debut, Victor Sanh, et al. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, 2020.

[48] Linfeng Xing, Yifan Wu, Zheng Li, Xin Zhao, Rui Zhao, and Jing Wang. Comparative analysis of pooling mechanisms in LLMs: A sentiment analysis perspective. *arXiv preprint arXiv:2411.14654*, 2024.

[49] Hiroto Yamato, Masato Okada, and Naoki Mori. Trainable weighted pooling method for text classification with BERT. In *2023 15th International Congress on Advanced Applied Informatics Winter (IIAI-AAI-Winter)*, pages 1–6, 2023.

[50] Erion Çano and Maurizio Morisio. MoodyLyrics: A sentiment annotated lyrics dataset. In *Proceedings of the International Conference on Intelligent Information Processing*. ACM, 2017.